

Flow Matching 实验报告

孙文辉, 电子工程系, 2025316110

2026 年 1 月 8 日

1 引言

Flow Matching [1] 提出了一种新的生成建模框架, 通过连续时间公式和最优传输 (Optimal Transport, OT) 路径, 实现了更简单的训练过程和更高效的采样。具体而言, Flow Matching 使用 OT 路径将噪声和数据通过直线连接, 形成常数速度的向量场, 使得 ODE 求解器可以使用更大的步长, 从而在更少的 NFE 下达到相同的生成质量。

本文从 0 开始, 复现了 Flow Matching 论文的核心实验, 在 2D Toy 数据和 CIFAR-10 数据集上完整实现了三种方法: Flow Matching (OT 路径)、Flow Matching (VP 路径) 和 DDPM baseline, 并通过 NFE 效率分析验证了 OT 路径的优势。除了在无条件生成任务上的实验, 我们还扩展实现了类别条件生成模型, 进一步展示了 Flow Matching 在条件生成任务中的潜力。

1.1 主要工作

- **算法复现与系统对比:** 在 2D Toy 和 CIFAR-10 数据集上完整复现了 Flow Matching (OT/VP 路径) 与 DDPM baseline。
- **采样效率验证:** 通过 NFE 效率分析验证了 OT 路径在低 NFE 下的显著优势, 相比 DDPM 实现了数倍的加速。
- **几何直觉分析:** 通过可视化手段揭示了 OT 路径 (直线) 与扩散模型路径 (曲线) 在训练复杂度和采样稳定性上的差异。
- **类别条件生成扩展:** 实现了基于 Cross-Attention 机制的类别条件生成模型, 展示了 Flow Matching 在条件生成任务中的有效性。

2 相关工作与核心理论

2.1 扩散模型与连续时间流

传统的扩散模型 (DDPM [2]) 通过模拟高斯扩散过程将数据转化为噪声。虽然其生成质量优秀, 但受限于 SDE 框架的随机性, 往往需要复杂的采样 schedule 和极高的采样步数。Score-Based Generative Models [4] 将其统一到连续时间框架下, 揭示了概率流 ODE 的存在。然而, 训练此类模型通常需要处理难以求解的 score function 或在训练循环中通过昂贵的数值积分来计算似然。

2.2 Flow Matching

Flow Matching [1] 的观点如下：既然知道噪声起点 x_0 和数据终点 x_1 ，就可以直接构建一条理想路径，并让神经网络学习该路径上的**速度（或者说向量场）**

1. 模拟 ODE 为回归向量场

假设存在概率路径 $p_t(x)$, $t \in [0, 1]$ ，其中 p_0 为高斯噪声， p_1 为数据分布。该路径由向量场 $v_t(x)$ 驱动，遵循连续性方程。Flow Matching 的目标是训练网络 $v_\theta(t, x)$ 逼近真实向量场 $u_t(x)$ 。

2. 条件流匹配 (CFM)

由于全局边缘分布 $p_t(x)$ 对应的真实向量场 $u_t(x)$ 涉及全局混合信息而不可解，论文提出了 CFM 定理：

$$\mathcal{L}_{CFM}(\theta) = \mathbb{E}_{t, q(x_1), p_t(x|x_1)} \|v_\theta(t, x) - u_t(x|x_1)\|^2 \quad (1)$$

这意味着只需学习针对单个数据点 x_1 的条件向量场 $u_t(x|x_1)$ 。定理证明，学好局部条件向量场等价于学好了全局边缘向量场，这使得损失函数退化为简单的均方误差 (MSE) 回归，无需在训练时解 ODE。从而大大简化了训练过程，提升了训练效率。

3. 最优传输路径 (Optimal Transport Path)

不同于扩散模型弯曲的路径，OT 路径在几何上是连接 x_0 与 x_1 的直线：

$$x_t = (1 - t)x_0 + tx_1 \implies u_t(x|x_1) = x_1 - x_0 \quad (2)$$

可以从以下几个方面理解 OT 路径的优势：

- **路径是直的**：相比扩散模型的比较混乱的收敛方式，OT 路径更加直接。
- **速度恒定**：目标速度 $x_1 - x_0$ 不随时间变化，神经网络极易拟合。
- **推理极快**：由于轨迹平直，Euler 法等简单积分器在极低 NFE 下即可精确采样。

3 方法实现

3.1 模型实现

本实验在两种规模的数据集上进行了验证：

- **2D Toy 数据**：使用多层感知机 (MLP) 拟合向量场，模型输入包含空间坐标与时间步，通过 Sinusoidal Embedding 处理时间特征。
- **CIFAR-10 图像**：采用 U-Net 架构作为向量场预测网络。模型通过 Residual Blocks 与 Self-Attention 层提取空间特征，并使用 Skip Connections 保持多尺度信息。

3.2 路径配置

本实验对比了三种路径：

- **OT (Optimal Transport)**：直线路径，向量场为 $x_1 - x_0$ 。
- **VP (Variance Preserving)**：基于三角函数的曲线路径，模拟扩散模型的演化轨迹。
- **DDPM (Baseline)**：传统加噪去噪路径，使用 DDIM 确定性采样进行推理。

3.3 类别条件生成扩展 (扩展部分)

为了进一步验证 Flow Matching 在条件生成任务中的表现，我们实现了基于类别标签的定向生成模型。

- **Cross-Attention 机制**：在 U-Net 的中间层与采样层引入交叉注意力机制。将类别标签通过 Learnable Embedding 转化为条件向量，作为 Attention 的 Key 和 Value，而图像特征作为 Query，从而实现特征图对类别信息的自适应捕捉。
- **轻量化架构**：设计了 UNetWithClassLabels 模型，参数量约为 2.4M。该模型在保持生成质量的同时，通过特征融合（Additive Fusion）与注意力引导，实现了高效的条件控制。

4 训练过程与演化分析

4.1 损失函数收敛

图 1 展示了三种方法在 CIFAR-10 上的训练损失曲线，图像左侧为 Loss，右侧为 NLL。可以看到，所有方法均在 1000 epoch 内实现了平稳收敛。相比 DDPM，基于 Flow Matching 的方法展现出更稳定的训练过程，基本在 200 epoch 后损失趋于平稳，说明向量场回归的训练目标更易优化。




图 1: 训练损失曲线对比。

4.2 样本演化对比

图 2 展示了模型在训练过程中的生成能力演化。为了方便展示，我们选取了第 10, 20, 50, 100, 1000 epoch 的采样结果：

从图中可以看出，OT 路径在训练的前 10 个 epoch 内就表现出了比 DDPM 更强的结构建模能力。DDPM 的训练效果相对滞后，在实际测试过程中，DDPM 即使在 1000 epoch 时也未能达到理想的生成质量，这某种程度上与我们的采样步数设置的不合理有关，但实际上，为了保证实验的公平性，三种模型都是用相同的采样步数，在后文对于 FID 的分析上也可以看出，基于 Flow Matching 的方法在低 NFE 下就能取得远超 DDPM 的效果。




图 2: 不同训练阶段的生成样本演化 (NFE=100)。OT 路径在早期即可捕捉到清晰的物体轮廓, 展现了强大的学习效率。

4.3 注：DDPM 的实验过程

由于没有复用现有的代码，全部模型都是从 0 开始的，加上期末周时间有限，跑一次完全的训练需要近 5 个小时，所以 DDPM 的实验结果可能并没有达到最优，我对于这种巨大的差异也感到诧异，事实上，DDPM 的现有结果是在经过修正 beta schedule 错误（训练过程使用了“cosine”而在采样过程中使用了“linear”）后得到的，之前的结果更差。不过即使如此，Flow Matching 的相对优势依然是显著的。在训练完成后，我对最后的模型使用不同的 NFE 进行了采样，结果如下：




图 3: 1000epoch 下 DDPM 在不同 NFE 下的结果

可以看到，在 NFE 步数足够的情况下，DDPM 的生成效果有明显的改善。


5 实验结果与效率评估

5.1 2D Toy 数据：几何直觉验证


为了直观体现 Flow Matching 的工作机制，我们在 2D Checkerboard 数据集上进行了详细的可视化分析。

5.1.1 粒子演化动力学


图 4 纵向展示了 OT、VP 和 DDPM 三种方法从噪声 ($t = 0$) 到数据 ($t = 1$) 的演化过程。



(a) FM (OT) 演化：粒子沿直线迅速汇聚，中间状态 ($t = 0.5$) 已具备较为清晰结构。



(b) FM (VP) 演化：呈现出类似于扩散过程的曲线运动特征。



(c) DDPM 演化：演化动力学相对滞后，噪声消除过程较为缓慢。

图 4: 2D Toy 粒子演化过程对比。

对比发现，OT 路径的粒子运动最具目的性，几乎没有冗余的布朗运动成分，在很短的时间内就能形成基本的结构轮廓然后在简单的直线路径上完成微调，这一现象在后面的向量场上也能够体现。这种高效的运动方式解释了其在低 NFE 下的优越表现。相比之下，DDPM 展现出更复杂的运动轨迹，粒子在空间中经历了更多的迂回和扩散过程，导致采样效率降低。


5.1.2 轨迹与向量场分析

进一步地，我们分析了微观层面的生成轨迹与向量场特性（图 5）。


1. **轨迹直线性**：OT 路径生成的轨迹在几何上接近连接噪声分布与数据流形的直线。这意味着 ODE 求解器可以用极大的步长进行积分而不产生显著的截断误差。
2. **向量场简单性**：OT 向量场在空间上变化平缓，方向一致性强。相比之下，VP 路径（以及传统的 DDPM）对应的向量场往往包含旋转和非线性变化，需要更深的网络和更多的采样步数来精确捕捉。

5.2 CIFAR-10 采样效率分析


本节通过 FID 随 NFE 变化的曲线（图 6）量化评估采样效率。



(a) 生成轨迹对比: OT (左) vs VP (右)



(b) OT 向量场 ($t = 0 - 1$)



(c) VP 向量场 ($t = 0 - 1$)

图 5: 微观机制分析。(a) 对于同一 Flow 过程, OT 的曲线要比 VP 更直。(b)-(c) OT 向量场呈现出整齐的一致性方向, 易于神经网络拟合; 相比之下, VP 向量场包含复杂的旋转分量 (Curl), 学习难度更大。




图 6: FID vs NFE 核心结果对比。OT 路径在极低步数下即可实现极高质量生成。

表 1: 不同步数下的 FID 性能对比 (仅部分, 测试样本数 2000)

Method	FID@10	FID@20	FID@50	FID@100	Best FID
FM-OT	51.54	44.16	44.02	44.33	43.76
FM-VP	106.28	58.47	45.92	43.93	43.23
DDPM	161.65	132.95	113.94	89.28	89.28

- **效率优势**: 在 $NFE=10$ 时, FM-OT 的 FID 已远超 $NFE=100$ 时的 DDPM, 实现极大的理论采样加速。
- **收敛稳定性**: OT 路径的 FID 随 NFE 增加表现出极强的稳定性, 说明其对步长选取不敏感, 这得益于其常数速度向量场的特性。
- **模型性能**: 虽然受到优化与模型设计的细节问题, 绝对 FID 高于原论文, 但是能够看出相对趋势与论文一致, 验证了 OT 路径在采样效率上的优势。

5.3 类别定向生成结果

通过引入 Cross-Attention 机制, 模型成功实现了对 CIFAR-10 十个类别的定向生成。图 7 展示了随机选取五个类别的生成结果。




图 7: 类别定向生成样本展示。模型能够准确根据输入标签生成具有对应语义特征的图像, 证明了 Flow Matching 框架在条件生成任务中的有效性。

实验表明, 基于 OT 路径的 Flow Matching 配合交叉注意力机制, 即便在较小的参数量 (2.4M) 下, 也能产生具有清晰轮廓和正确语义的样本。这进一步验证了向量场回归在处理复杂条件分布时的灵活性。

6 结论

本文基本复现了 Flow Matching 论文的核心实验, 在 2D Toy 数据和 CIFAR-10 数据集上验证了最优传输 (OT) 路径的优势。通过完整实现 OT、VP、DDPM 三种方法并进行系统对比, 我们发现:

1. OT 路径在低 NFE 下显著优于 VP 路径和 DDPM;
2. Flow Matching 训练更简单, 无需复杂的 beta schedule 设计;
3. 向量场可视化验证了理论: OT 路径的方向一致, 易于学习; VP 路径有旋度, 模式复杂
4. 实验结果的相对趋势与 Flow Matching 论文一致, 验证了 OT 路径在采样效率上的优势

参考文献

- [1] Y. Lipman *et al.*, “Flow matching for generative modeling,” in *International Conference on Learning Representations (ICLR)*, 2023.
- [2] J. Ho, A. Jain, and P. Abbeel, “Denoising diffusion probabilistic models,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [3] J. Song, C. Meng, and S. Ermon, “Denoising diffusion implicit models,” in *International Conference on Learning Representations (ICLR)*, 2021.
- [4] Y. Song, J. Sohl-Dickstein, D. P. Kingma *et al.*, “Score-based generative modeling through stochastic differential equations,” in *International Conference on Learning Representations (ICLR)*, 2021.
- [5] M. Heusel, H. Ramsauer, T. Unterthiner *et al.*, “Gans trained by a two time-scale update rule converge to a local nash equilibrium,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

AI 使用情况说明：报告写作的过程中使用了 gemini 与 copilot，但是由于这个实验项目相对较为复杂，仅实验结果就有数百张图像，所以 gemini 主要用于基本的 latex 的框架搭建与语言润色，copilot 主要用于 tabletabletable 进行一部分补全，实验结果与分析均为本人独立完成。